

5 Palle, urne e grafi: Alessandro

5.1 Paradosso del compleanno

Supponiamo per assurdo che 30 persone stiano assistendo alla lezione

È più probabile che almeno due persone facciano il compleanno lo stesso giorno dell'anno oppure no?

Soluzione Combinatoria

Per semplicità supponiamo ciascuno abbia una data di compleanno distribuita uniformemente sui 365 giorni

Sia

$$E = \{\text{nessuno condivide la data del compleanno}\}$$

Allora

$$P(E) = \frac{\binom{365}{30} \cdot 30!}{365^{30}}$$

Dove:

- $\binom{365}{30}$ sono i modi di scegliere 30 date sulle 365 disponibili
- $30!$ indica come queste vengono assegnate alle 30 persone
- 365^{30} sono tutte le possibili combinazioni di date di compleanno

Soluzione Probabilistica

Immaginiamo di considerare una persona alla volta

La prob. che le prime due persone abbiano la data di compleanno diversa è $\left(1 - \frac{1}{365}\right)$

La prob. che la terza abbia il compleanno diverso dalle prime due è

Sapendo che le prime due sono diverse

$$\left(1 - \frac{2}{365}\right)$$

Continuando così, la prob. che la k -esima persona abbia il compleanno diverso dalle prime $k-1$,

Sapendo che le $k-1$ precedenti abbiano un compleanno differente fra loro è

$$\left(1 - \frac{k-1}{365}\right)$$

Quindi la probabilità che 30 persone abbiano compleanno diverso è

$$P(E) = \left(1 - \frac{1}{365}\right) \left(1 - \frac{2}{365}\right) \dots \left(1 - \frac{29}{365}\right) \approx 0.2837$$

Allora la prob. che due persone facciano il compleanno nello stesso data è più del 70%!

In generale se ci fossero n possibili date di compleanno ed m persone

$$P(E) = \prod_{j=1}^{m-1} \left(1 - \frac{j}{n}\right)$$

Se cerchiamo un'espressione più semplice che approssimi questa possiamo usare che $1 - \frac{j}{n} \approx e^{-\frac{j}{n}}$ quando $j \ll n$ ottenendo quindi

$$P(E) \approx \prod_{j=1}^{m-1} e^{-\frac{j}{n}} = e^{-\sum_{j=1}^{m-1} \frac{j}{n}} = e^{-\frac{1}{n} \frac{m(m-1)}{2}} \approx e^{-\frac{m^2}{2n}}$$

Assinche $P(E) \approx \frac{1}{2}$ bisogna avere $\frac{m^2}{2n} = \log 2$ cioè $m = \sqrt{2n \log n}$

5.2 Modelli di Urne

Il paradosso del compleanno è un esempio di modello di urne

Immaginiamo di avere m palle ed n urne

Ogni palla viene tirata a caso in una delle n urne. Qual'è la distribuzione probabilistica del numero di palle in ogni urna?

Sia $Z_i = \{\text{di palline nella } i\text{-esima urna}\}$

Allora $V_i = 1, \dots, n$ e $V_r = 1, \dots, m$

$$P(Z_i = r) = \binom{m}{r} \left(\frac{1}{n}\right)^r \left(1 - \frac{1}{n}\right)^{m-r} = P_r(m, n) \quad \text{poiché } Z_i \sim \text{Bin}\left(\frac{1}{n}, m\right)$$

Nota

→ Sono tutte $\text{Bin}\left(\frac{1}{n}, m\right)$

Osserviamo che le Z_i sono identicamente distribuite, ma non indipendenti visto che la loro somma dà sempre m : $Z_1 + \dots + Z_n = m$

Oss

Il paradosso dei compleanni mostra ad esempio che

$$P(\exists i \in \{1, \dots, n\} : Z_i = z) \geq \frac{1}{2} \quad \text{se} \quad m \geq \sqrt{2n \log 2}$$

Esempio

Possiamo chiederci: qual'è il numero medio di urne rimaste vuote?

$$\text{Sia } X_i = \begin{cases} 1 & \text{se l'i-esima urna rimane vuota} \\ 0 & \text{altrimenti} \end{cases}$$

Allora

$$P(X_i = 1) = \left(1 - \frac{1}{n}\right)^m \rightarrow \text{tutte le } m \text{ palline vanno nelle altre urne}$$

e quindi

$$E[\# \text{ urne vuote}] = E\left[\sum_{i=1}^n X_i\right] = n \left(1 - \frac{1}{n}\right)^m \approx n e^{-\frac{m}{n}}$$

$\hookrightarrow$ L'appa $1-x \approx e^{-x}$ è molto buona per x piccoli

In generale $\forall x \in (0,1) \quad 1-x \leq e^{-x} \leq 1 - \frac{x}{2}$

Tornando a $P(Z_i = r)$ abbiamo che

$$P(Z_i = r) = P_r(m, n) = \binom{m}{r} \left(\frac{1}{n}\right)^r \left(1 - \frac{1}{n}\right)^{m-r} = \frac{1}{r!} \frac{m(m-1) \dots (m-r+1)}{n^r} \left(1 - \frac{1}{n}\right)^{m-r}$$

Se $m \gg r$ e $n \gg r$ possiamo approssimare il secondo termine con $\left(\frac{m}{n}\right)^r$ e il terzo con $e^{-\frac{m}{n}}$ ottenendo

$$P_r(m, n) \approx \frac{e^{-\frac{m}{n}} \left(\frac{m}{n}\right)^r}{r!}$$

Nota

Per essere più precisi del libro, si ha che, se $\frac{m}{n} \rightarrow s$ per qualche $s > 0$

$$\lim_{\substack{m \rightarrow \infty \\ n \rightarrow \infty \\ \frac{m}{n} \rightarrow s}} P_r(m, n) = \frac{s^r e^{-s}}{r!} \quad \forall r \geq 0$$

Queste app motivano l'introduzione della prossima v.a.

Def 5.1

Una v.a. X è detta di Poisson di parametro μ , ovvero $X \sim \text{Poi}(\mu)$, se

$$P(X=k) = e^{-\mu} \frac{\mu^k}{k!} \quad \forall k=0,1,2,\dots$$

↳ Da non confondere con le

Poisson Trials

Nota

Un'interpretazione classica delle Poisson è

- a) X è il numero di telefonate che arrivano ad un centralino in un'arco di tempo dato
- b) X è il numero di terremoti che si verificano in una data regione in un'arco di tempo dato

Per $X \sim \text{Poi}(\mu)$ si ha

$$\begin{aligned} E[X] &= \sum_{k=0}^{\infty} k e^{-\mu} \frac{\mu^k}{k!} = \\ &= e^{-\mu} \mu \sum_{k=1}^{\infty} \frac{\mu^{k-1}}{(k-1)!} = \\ &= e^{-\mu} \mu \sum_{j=0}^{\infty} \frac{\mu^j}{j!} = \text{Cambio di variabile } j=k-1 \\ &= e^{-\mu} \mu e^{\mu} = \mu \end{aligned}$$

La S.g.m. invece vale

$$\begin{aligned} M_X(t) &= E[e^{tX}] = \sum_{k=0}^{\infty} e^{tk} e^{-\mu} \frac{\mu^k}{k!} = \\ &= e^{-\mu} \sum_{k=0}^{\infty} \frac{(\mu e^t)^k}{k!} = \\ &= e^{\mu(e^t-1)} \quad \forall t \in \mathbb{R} \end{aligned}$$

Tramite S.g.m. si può calcolare anche la varianza

$$\begin{aligned} E[X^2] &= M''_X(t) \Big|_{t=0} = \frac{\partial^2}{\partial t^2} e^{\mu(e^t-1)} = \\ &= \frac{\partial}{\partial t} \mu e^t e^{\mu(e^t-1)} \Big|_{t=0} \\ &= \mu e^t e^{\mu(e^t-1)} + \mu^2 e^{2t} e^{\mu(e^t-1)} \Big|_{t=0} \\ &= \mu^2 + \mu \end{aligned}$$

Così che

$$\text{Var}(X) = E[X^2] - (E[X])^2 = \mu^2 + \mu - \mu^2 = \mu$$

Lemma 5.2

Siano $X_1, \dots, X_n$ v.a. di Poisson di parametri $\mu_1, \dots, \mu_n$ indipendenti

Allora

$$Y = \sum_{i=1}^n X_i \sim \text{Poi}\left(\sum_{i=1}^n \mu_i\right)$$

Dim

Calcoliamo la S.g.m. di Y

$$\begin{aligned} M_Y(t) &= E[e^{Yt}] = E[e^{t \sum_{i=1}^n X_i}] = \\ &= \prod_{i=1}^n E[e^{tX_i}] = \\ &= \prod_{i=1}^n e^{\mu_i(e^t-1)} = e^{(\sum_{i=1}^n \mu_i)(e^t-1)} \end{aligned}$$

La quale è la S.g.m. di uno $\text{Poi}(\sum_{i=1}^n \mu_i)$

Thm 5.4 disuguaglianza di Chernoff per una singola v.a. di Poisson

$$\text{Sia } X \sim \text{Poi}(\mu)$$

Allora

1) Se $y > \mu$:

$$\mathbb{P}(X \geq y) \leq \frac{e^\mu}{y^\mu} e^{-y}$$

2) Se $y < \mu$:

$$\mathbb{P}(X \leq y) \leq \frac{e^\mu}{y^\mu} e^{-y}$$

Dim

Applichiamo l'esponentiale $\rightarrow$ Markov $\rightarrow$ ottimizzazione

1) Per $t > 0$

$$\mathbb{P}(X \geq y) = \mathbb{P}(e^{Xt} \geq e^{yt}) \leq \frac{\mathbb{E}[e^{Xt}]}{e^{yt}} = e^{\mu(e^t - 1) - yt} \quad \leadsto \text{da verificare}$$

Il minimo si ottiene per $t = \log(\frac{y}{\mu}) > 0$ Per cui

$$\mathbb{P}(X \geq y) \leq e^{\mu(\frac{y}{\mu} - 1) - y \log(\frac{y}{\mu})} = \frac{(e\mu)^y}{y^y} e^{-\mu}$$

2) Per $t < 0$

$$\mathbb{P}(X \leq y) = \mathbb{P}(e^{Xt} \geq e^{ty}) \leq e^{\mu(e^t - 1) - yt}$$

E si conclude ponendo $t = \log(\frac{y}{\mu}) < 0 \leadsto$ negativo visto che $y < \mu$

Corollario $\leadsto$ Punti 3 e 4 del Thm sul libro

$$\text{Sia } X \sim \text{Poi}(\mu)$$

Allora

$$3) \mathbb{P}(X \geq (1+\delta)\mu) \leq \left(\frac{e^\delta}{(1+\delta)^{1+\delta}} \right)^\mu \quad \forall \delta > 0$$

$$4) \mathbb{P}(X \leq (1-\delta)\mu) \leq \left(\frac{e^{-\delta}}{(1-\delta)^{1-\delta}} \right)^\mu \quad \forall \delta \in (0, 1)$$

Dim

Basta usare i punti 1 e 2 del Thm 5.4