

Eser 4.13

Notiamo che $X = \sum_{i=1}^n X_i$ è una Bin(n, p) con media $E[X] = np$.

(a) Per $x=1$ si ha facilmente che

$$F(1, p) = \log \frac{1}{p} \quad (\text{ricordiamo che } "0 \cdot \log 0 = 0")$$

e che

$$P(X \geq n) = P(X = n) = p^n = e^{-n \log \frac{1}{p}} = e^{-n F(1, p)}$$

Per $x \in (p, 1)$ facciamo il solito esponentiale $\rightarrow$
 $\rightarrow$ Markov $\rightarrow$ ottimizzazione: $\forall t > 0$

$$P(X \geq nx) = P(e^{tx} \geq e^{tnx}) \leq \frac{E[e^{tX}]}{e^{tnx}}$$

Abbiamo calcolato esattamente la f.g.m. della Bin(n, p) nell'eser. 4.3:

$$E[e^{tX}] = (pe^t + 1 - p)^n$$

Quindi

$$P(X \geq nx) \leq \frac{(pe^t + 1 - p)^n}{e^{tnx}} = e^{n(\log(pe^t + 1 - p) - tx)}$$

Ottimiziamo in t . Poniamo

$$f(t) := \log(pe^t + 1 - p) - tx$$

e troviamo il minimo.

$$f'(t) = \frac{pe^t}{pe^t + 1 - p} - x$$

e quindi

$$f'(t) > 0 \iff \frac{pe^t}{pe^t + 1 - p} > x$$

$$\iff 1 + \frac{1-p}{pe^t} < \frac{1}{x}$$

$$\iff \frac{1-p}{pe^t} < \frac{1}{x} - 1$$

$$\iff e^t > \frac{1-p}{p} \cdot \frac{x}{1-x}$$

$$\iff t > \log\left(\frac{1-p}{p} \cdot \frac{x}{1-x}\right)$$

Quindi $f(t)$ decresce fino a $t^* := \log\left(\frac{1-p}{p} \cdot \frac{x}{1-x}\right) \in (0, 1)$ e poi cresce. Quindi il minimo è raggiunto in t^* . Calcoliamo

$$f(t^*) = \log[pe^{t^*} + 1 - p] - t^*x$$

$$\begin{aligned}
&= \log \left(\frac{1-p}{1-x} \overset{+1-p}{x} \right) - x \log \left(\frac{1-p}{p} \frac{x}{1-x} \right) \\
&= \log \left(\cancel{\frac{1-p}{1-x}} (1-p) \underbrace{\left(\frac{x}{1-x} + 1 \right)}_{= \frac{1}{1-x}} \right) - x \log \frac{x}{p} - x \log \frac{1-p}{1-x} \\
&= \log \left(\frac{1-p}{1-x} \right) - x \log \frac{x}{p} - x \log \frac{1-p}{1-x} \\
&= - \left[x \log \frac{x}{p} + (1-x) \log \frac{1-x}{1-p} \right] \\
&= -F(x, p).
\end{aligned}$$

(b) Definiamo la funzione (considerando p fissato)

$$\begin{aligned}
\Delta(x) &= F(x, p) - 2(x-p)^2 \\
&= x \log \frac{x}{p} + (1-x) \log \frac{1-x}{1-p} - 2(x-p)^2
\end{aligned}$$

Vogliamo mostrare che $\Delta(x) \geq 0 \quad \forall x \in (0, 1)$.

Seguendo l'hint del libro

$$\begin{aligned}
\Delta'(x) &= \log \frac{x}{p} + \overset{=1}{x \cdot \frac{1}{x}} - \log \frac{1-x}{1-p} + \overset{=-1}{(1-x) \frac{1-p}{1-x} \cdot \left(-\frac{1}{1-p} \right)} \\
&\quad - 4(x-p) \\
&= \log \left(\frac{x}{p} \frac{(1-p)}{(1-x)} \right) - 4(x-p)
\end{aligned}$$

$$\Delta''(x) = \frac{1-x}{x} \cdot \frac{1-x+x}{(1-x)^2} - 4 = \frac{1}{x(1-x)} - 4$$

$$\Delta'''(x) = - \frac{1-2x}{x^2(1-x)^2}$$

Siccome $\Delta'''(x) > 0 \Leftrightarrow x > \frac{1}{2}$, segue che

$\Delta''(x)$ cresce $\Leftrightarrow x > \frac{1}{2}$. In particolare

$$\Delta''(x) \geq \Delta''\left(\frac{1}{2}\right) = 0 \quad \forall x \in (0, 1).$$

Quindi $\Delta'(x)$ cresce per $x \in (0, 1)$. Poiché

$$\lim_{x \rightarrow 0^+} \Delta'(x) = -\infty$$

$$\lim_{x \rightarrow 1^-} \Delta'(x) = +\infty$$

e Δ' è continua, segue che $\Delta'(x)$ assume (crescendo) tutti i valori tra $(-\infty, +\infty)$ quando $x \in (0, 1)$. Notiamo

infine che $\Delta'(p) = 0$, e quindi

$\Delta(x)$ cresce se e solo se $x > p$. Ne

concludiamo che

$$\Delta(x) \geq \Delta(p) = 0 \quad \forall x \in (0, 1)$$

che era quello che volevamo dimostrare.

(C) Se $p + \varepsilon > 1$ la relazione vale banalmente perché

$$P(X > (p + \varepsilon)n) = 0$$

(ricordiamo che $X \sim \text{Bin}(n, p)$ e quindi assume valori in $\{1, \dots, n\}$). Se $p + \varepsilon \leq 1$, usiamo la parte (a) con $x = p + \varepsilon$ e

otteniamo

$$P(X \geq n(p + \varepsilon)) \leq e^{-nF(p + \varepsilon, p)};$$

poiché dalla parte (b) sappiamo che

$$F(p + \varepsilon, p) \geq 2(p + \varepsilon - p)^2 = 2\varepsilon^2,$$

deduciamo che

$$P(X \geq n(p + \varepsilon)) \leq e^{-2n\varepsilon^2}.$$

(d) Definiamo la v.a.

$$Y = n - X.$$

Y è una Binomiale ($n, 1-p$), poiché
 "conta" i fallimenti su n prove ^{indipendenti}, ciascuno
 dei quali avviene con proba $1-p$. Sia $\tilde{p} = 1-p$.

Perciò

$$\begin{aligned} P(X \leq n(p-\varepsilon)) &= P(-X \geq -n(p-\varepsilon)) \\ &= P(n-X \geq n - n(p-\varepsilon)) \\ &= P(Y \geq n(1-p+\varepsilon)) \\ &= P(Y \geq n(\tilde{p}+\varepsilon)) \\ &\leq e^{-2n\varepsilon^2} \\ &\quad \uparrow \\ &\quad \text{dalla parte (b).} \end{aligned}$$

Infine

$$P(|X - np| \geq n\varepsilon) = P(X - np \geq n\varepsilon) + P(X - np \leq -n\varepsilon)$$

$$= P(X \geq n(p+\varepsilon)) + P(X \leq n(p-\varepsilon))$$

$$\leq e^{-2n\varepsilon^2} + e^{-2n\varepsilon^2}$$

$$= 2e^{-2n\varepsilon^2}.$$

CAPITOLO VI : PALE, URNE E

20.04.'23

GRAFI ALEATORI5.1 Il paradosso del compleanno

Supponiamo (per assurdo) che 30 persone stiano assistendo a questa lezione. È più probabile che due persone almeno abbiano il compleanno nello stesso giorno dell'anno oppure no?

Soluzione combinatorica Per semplicità supponiamo ciascuno abbia una data di compleanno distribuita uniformemente su 365 possibili giorni. Sia

$$E = \{ \text{Nessuno condivide la data del compleanno} \}.$$

Allora

$$P(E) = \frac{\binom{365}{30} \cdot 30!}{365^{30}}$$

134

Infatti: $\binom{365}{30}$ sono i modi di scegliere

30 date diverse sulle 365 disponibili.

Queste 30 date vanno "assegnate" alle 30 persone, e ci sono $30!$ modi di farlo.

365^{30} sono tutte le possibili combinazioni di date di compleanno per 30 persone.

Soluzione "probabilistica" Immaginiamo di

considerare una persona alla volta. La probabilità che le prime due persone abbiano la ~~stessa~~ data di compleanno diversa è

$$\left(1 - \frac{1}{365}\right)$$

La probabilità che la terza persona abbia il compleanno diverso dalle prime due è, sapendo che le prime due erano diverse,

$$\left(1 - \frac{2}{365}\right).$$

(135)

Continuando così, la probabilità che la k -esima persona abbia il compleanno diverso dalle prime $k-1$, sapendo che quelle $k-1$ hanno compleanno diverso tra loro, è

$$\left(1 - \frac{k-1}{365}\right).$$

Quindi la probabilità che 30 persone abbiano compleanno diverso è

$$P(E) = \left(1 - \frac{1}{365}\right) \cdot \left(1 - \frac{2}{365}\right) \cdot \left(1 - \frac{3}{365}\right) \cdot \dots \cdot \left(1 - \frac{29}{365}\right)$$

(verificate che questo prodotto vale $\frac{\binom{365}{30} \cdot 30!}{365^{30}}$)

Questo numero vale circa 0.2937. Quindi la probabilità che due persone nella sala abbiano la stessa data di compleanno è più del 70% !

Fun fact: rifacendo i calcoli si può vedere che a partire da 23 persone diventa più probabile avere 2 persone con lo stesso compleanno piuttosto che no.

In generale se ci fossero n possibili date di compleanno ed m ~~persone~~ persone

$$P(E) = \prod_{j=1}^{m-1} \left(1 - \frac{j}{n}\right)$$

Se cerchiamo un'espressione più semplice che approssimi questa possiamo usare che $1 - \frac{j}{n} \approx e^{-\frac{j}{n}}$ quando $j \ll n$, ottenendo

$$\begin{aligned} P(E) &\approx \prod_{j=1}^{m-1} e^{-\frac{j}{n}} = e^{-\frac{1}{n} \sum_{j=1}^{m-1} j} \\ &= e^{-\frac{1}{n} \frac{m(m-1)}{2}} \approx e^{-\frac{m^2}{2n}} \end{aligned}$$

Affinche $P(E) \approx \frac{1}{2}$ dobbiamo avere $\frac{m^2}{2n} = \log 2$

cioè $m = \sqrt{2n \log 2}$ (per $n=365$ questo

valore $\bar{m} \approx 22.49$, che è molto vicino al nostro calcolo esatto).

5.2 Modelli di urne

Il paradosso del compleanno è un esempio di modello di urne. Immaginiamo di avere

m palle & n urne.

Ogni palla viene tirata a caso in una delle urne. Qual è la distribuzione probabilistica del numero di palle in ogni urna?

Sia $Z_i := \# \{ \text{palline nella } i\text{-esima urna} \}$.

Allora $\forall i=1, \dots, n$ e $\forall r=0, 1, \dots, m$

$$P(Z_i=r) = \binom{m}{r} \left(\frac{1}{n}\right)^r \left(1 - \frac{1}{n}\right)^{m-r} =: P_r(m, n)$$

poiché $Z_i \sim \text{Bin}\left(\frac{1}{n}, m\right)$.

Nota Osserviamo che le z_i sono identicamente distribuite (sono tutte $\text{Bin}(m, \frac{1}{n})$), ma non indipendenti, visto che la loro somma deve dare sempre m : $z_1 + \dots + z_n = m$.

Oss. Il paradosso dei compleanni mostrava ad esempio che

$$P(\exists i \in \{1, \dots, n\}: z_i \geq 2) \geq \frac{1}{2}$$

se $m \geq \sqrt{2n \log 2} \dots$

ex. Possiamo chiederci: qual è il numero medio di urne rimaste vuote?

Sia $X_i = \begin{cases} 1 & \text{se l'i-esima urna rimane vuota} \\ 0 & \text{altrimenti} \end{cases}$

Allora $P(X_i = 1) = (1 - \frac{1}{n})^m \approx e^{-\frac{m}{n}}$

↑ m palline vanno in una delle altre $n-1$ urne

e quindi

$$E[\#\{\text{Urne vuote}\}] = E\left[\sum_{i=1}^n X_i\right] = n \cdot \left(1 - \frac{1}{n}\right)^m \approx n e^{-\frac{m}{n}}. \quad (139)$$

Nota

L'approssimazione $1-x \approx e^{-x}$ è molto buona se x è piccolo (la useremo spesso). In generale è vero che $\forall x \in (0,1)$

$$1-x \leq e^{-x} \leq 1 - \frac{x}{2}$$

Torniamo a

$$\begin{aligned} P(Z_i = r) &=: P_r(m, n) = \binom{m}{r} \left(\frac{1}{n}\right)^r \left(1 - \frac{1}{n}\right)^{m-r} \\ &= \frac{1}{r!} \frac{m(m-1) \cdots (m-r+1)}{n^r} \left(1 - \frac{1}{n}\right)^{m-r} \end{aligned}$$

Se $m \gg r$ e $n \gg r$ possiamo approssimare il secondo termine con $\left(\frac{m}{n}\right)^r$ e il terzo con $e^{-\frac{m}{n}}$ ottenendo

$$P_r(m, n) \approx \frac{e^{-\frac{m}{n}} \left(\frac{m}{n}\right)^r}{r!}$$

Nota Per essere più precisi del libro,
si ha che, se $\frac{m}{n} \rightarrow s$ per qualche $s > 0$,

$$\lim_{\substack{m \rightarrow \infty \\ n \rightarrow \infty \\ \frac{m}{n} \rightarrow s}} P_r(m, n) = \frac{s^r e^{-s}}{r!} \quad \forall r \geq 0$$

Queste approssimazioni motivano l'introduzione della prossima (importantissima) variabile aleatoria:

Def. 5.1

Una v.a. X è detta di Poisson di parametro μ , ovvero $X \sim \text{Poi}(\mu)$, se

$$P(X = k) = e^{-\mu} \frac{\mu^k}{k!} \quad \forall k = 0, 1, 2, \dots$$

(da NON confondere con le Poisson trials!)

Nota

Un'interpretazione classica della Poisson $\bar{e}$: $X \bar{e}$ il numero di telefonate che arrivano ad un centralino in un arco di tempo dato. Oppure: $X \bar{e}$ il numero di terremoti che si verificano in una data regione in un certo arco di tempo.

Per $X \sim \text{Poi}(\mu)$ si ha

$$E[X] = \sum_{k=0}^{\infty} k e^{-\mu} \frac{\mu^k}{k!}$$

$$= e^{-\mu} \mu \sum_{k=1}^{\infty} \frac{\mu^{k-1}}{(k-1)!}$$

cambio
variabile
 $j = k-1$

$$\downarrow = e^{-\mu} \mu \sum_{j=0}^{\infty} \frac{\mu^j}{j!}$$

$$= e^{-\mu} \mu e^{\mu}$$

$$= \mu$$

La f.g.m. vale invece

$$\begin{aligned}
 M_X(t) &= \mathbb{E}[e^{tX}] = \sum_{k=0}^{\infty} e^{tk} e^{-\mu} \frac{\mu^k}{k!} \\
 &= e^{-\mu} \sum_{k=0}^{\infty} \frac{(\mu e^t)^k}{k!} \\
 &= e^{\mu(e^t - 1)} \quad \forall t \in \mathbb{R}.
 \end{aligned}$$

Con la f.g.m. possiamo anche calcolare la varianza:

$$\begin{aligned}
 \mathbb{E}[X^2] &= M_X''(t) \Big|_{t=0} = \frac{d^2}{dt^2} e^{\mu(e^t - 1)} \Big|_{t=0} \\
 &= \frac{d}{dt} \mu e^t e^{\mu(e^t - 1)} \Big|_{t=0} \\
 &= \mu e^t e^{\mu(e^t - 1)} + \mu^2 e^{2t} e^{\mu(e^t - 1)} \Big|_{t=0} \\
 &= \mu + \mu^2
 \end{aligned}$$

così che

$$\text{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2 = \mu.$$

Lemma 5.2 (Variato rispetto al libro)

Siano $X_1, \dots, X_n$ v.a. di Poisson di parametri $\mu_1, \dots, \mu_n$ rispettivamente, che siano indipendenti. Allora

$$Y = \sum_{i=1}^n X_i \sim \text{Poi} \left(\sum_{i=1}^n \mu_i \right).$$

Dim.

Calcoliamo la f.g.m. di Y :

$$M_Y(t) = \mathbb{E}[e^{tY}] = \mathbb{E}[e^{t \sum_{i=1}^n X_i}]$$

$$\xrightarrow{\text{indipendenza}} \prod_{i=1}^n \mathbb{E}[e^{tX_i}]$$

$$\xrightarrow{\text{formula per } M_{X_i}(t)} \prod_{i=1}^n e^{\mu_i(e^t - 1)}$$

$$= e^{\left(\sum_{i=1}^n \mu_i\right)(e^t - 1)}$$

che è la f.g.m. di una Poisson di parametro $\sum_{i=1}^n \mu_i$.

□

