Approcci al Machine Learning

L'idea alla base di tutto il Machine Learning è che raramente i dati sono realmente random

Lo scopo quindi è cercare di stimare il pattern seguito da questi dati senza cercare le reali regole da cui questi sono governati

Paradigmi del ML

Vediamo ora i 3 approcci principali al ML

a) Apprendimento Supervisionato:

Basato su coppie osservazioni e target, lo scopo è capire le relazioni che le legano in modo da predire i target di nuovi input

b) Apprendimento non Supervisionato

Lavorando senza target specifici si cerca una qualche struttura per i dati, ad esempio clusterizzare dati simili

c) Apprendimento con rinforzo

Il modello invece di apprendere mediante un data set lo fa attraverso delle interazioni a cui seguirà un qualche tipo di reward

Apprendimento Supervisionato

Focalizziamoci ora sul primo approccio

Vediamo che esistono due categorie in base al tipo di target

a) Regressione:

Il target è un numero reale ⇝ prezzi, temperature...

b) Classificazione:

Il target appartiene ad un'insieme di categorie discrete ⇝ classificatore binario

Rappresentazione dei dati

Nel ML è fondamentale capire come rappresentare i dati

Questi vengono convertiti nei feature vector

$x = (x_1, \dots, x_d)$ ↗ Modellato attraverso feature engineering

Ovvero una combinazione di d parametri numerici che descrivono un'oggetto

Learning process

Visto che lo scopo del ML supervisionato è dato in input un feature vector associargli un target dobbiamo definire gli insiemi a cui essi appartengono

Def

Sia $\mathcal{X}$ il domain set t.c. $\forall x \in \mathcal{X}$ è un feature vector

$x = (x_1, \dots, x_d)$ d-dimensionale ⇝ Più d aumenta più cresce la complessità del modello

Sia Y il label set set contenente tutti i possibili output

Oss

Se $Y \subset \mathbb{R}$ stiamo parlando di regressione

Se $Y \subset \mathbb{N}$ stiamo parlando di classificazione

Abbiamo bisogno di una collezione di esempi chiamati Training set su cui allenare il nostro modello

Def

Un Training set $T = \{(x_1, t_1), \dots, (x_n, t_n)\}$ è un'insieme di esempi a cui ad ognuno dei feature vector $x_i = (x_1, \dots, x_d) \in \mathcal{X}$ viene associato un target $t_i \in Y$

Possiamo modellare T come una matrice composta da una feature matrix e un target vector

$$T = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1d} & t_1 \\ \vdots & & & & \\ x_{n1} & x_{n2} & \cdots & x_{nd} & t_n \end{pmatrix}$$

n righe, $d+1$ colonne

Il nostro obiettivo ora è quello di costruire un'algoritmo A che preso un feature vector mi restituisca un target

L'algo A viene costruito mediante un predittore $\mathcal{L}$ il quale è un'algoritmo che può essere di 2 tipi

i) Functional predictor

ii) Probabilistic predictor

Functional predictors

Def

Un predittore di questo tipo è una funzione

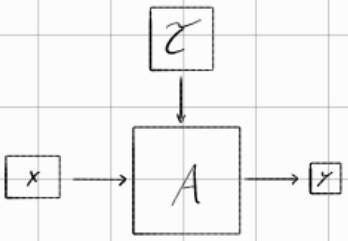
$$h: \mathcal{X} \longrightarrow \mathcal{Y}$$

Nella maggior parte dei casi però $h: \mathcal{X} \to \mathbb{R}$ assegna un valore detto score al quale viene associato un target attraverso una decision rule $d: \mathbb{R} \to \mathcal{Y}$

Esistono 3 diverse tipologie di predittori funzionali:

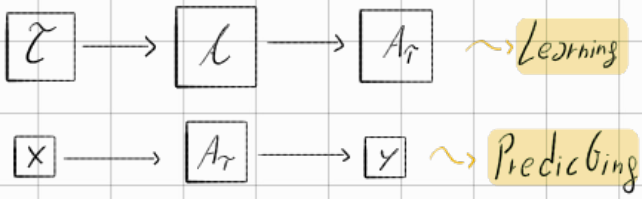
i) Direct prediction

In questo caso un'algoritmo predefinito va ad associare ad un nuovo item $x \in \mathcal{X}$ un target comparandolo con tutto il Training set



ii) Model based predictors

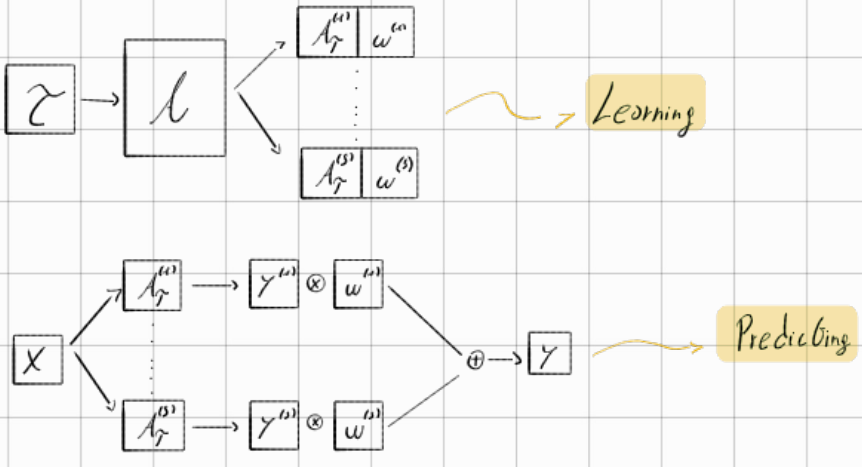
Questo approccio si basa sul definire una hypothesis class $\mathcal{H}$, una famiglia di funzioni che mappano $\mathcal{X}$ in $\mathcal{Y}$ in modo che si scelga la funzione A_T che meglio descrive T



iii) Ensemble Learning

Questo si basa sul costruire più predittori e poi combinare le loro predizioni

Più nello specifico si vanno a creare s predittori $A_T^{(1)}, \dots, A_T^{(s)}$ a cui viene associato un peso $w^{(i)}$ in base alla qualità del predittore costruito



Probabilistic predictors

Fino ad ora abbiamo visto solo predittori funzionali, vediamo ora quelli probabilistici

Def

Un predittore probabilistico è una funzione

$h: \mathcal{X} \longrightarrow \mathcal{D}(\mathcal{Y})$ Dove $\mathcal{D}(\mathcal{Y})$ è una distribuzione di prob. su $\mathcal{Y}$

Nello specifico abbiamo che

$\forall x \in \mathcal{X}\ h(x) = p_p(\cdot|x)$ su $\mathcal{Y}$

Decisionatori

Solitamente al predittore è segue una regola di decisione

$d: \mathbb{R} \longrightarrow \mathcal{Y}$

Che varia in base alle necessità:

i) Regressione:

Avendo $\mathcal{Y} = \mathbb{R}$, la regola di decisione è la media a posteriori

$$\tilde{y} = d(p_p) = \mathop{\mathbb{E}}_{t \sim p_p(\cdot|x)}[t]$$

→ Dubbi i possibili valori di $p_p(\cdot|x)$

ii) Classificazione binaria:

Avendo $\mathcal{Y} = \{-1, 1\}$, la regola di decisione è la moda a posteriori

$$\tilde{y} = d(p_p) = \arg\max_{t \in \mathcal{Y}} p_p(t|x)$$

↳ sarebbe $p_p(\cdot|x)$

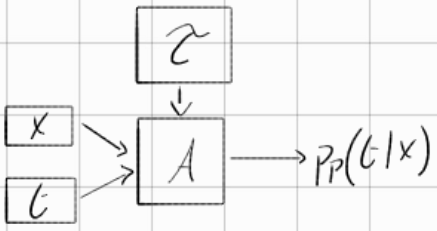
↳ Ci sarebbe anche la classificazione multiclasse ma è la binaria con $\mathcal{Y} = \{y_1, \dots, y_k\}$

Approcci

Come per i predittori funzionali abbiamo i diversi approcci per i predittori probabilistici

i) Direct prediction:

Abbiamo direttamente un'algoritmo A che prende in input l'input x, un possibile target t ed interpellando $\tilde{\mathcal{L}}$ ci da' in output $p_p(t|x)$



ii) Model based Learning:

Come nel funzionale abbiamo un' algoritmo $\mathcal{A}$ che preso $\tilde{\mathcal{L}}$ ci genera un $A_{\tilde{\mathcal{L}}}$ che altro non sarebbe che $p_p(\cdot|x;\tilde{\mathcal{L}})$ scelto all'interno di una famiglia di distribuzioni condizionali $p^*(\cdot|\theta)$

Questo viene scelto minimizzando il fattore di rischio empirico

Learning $\tilde{\mathcal{L}} \longrightarrow \mathcal{A} \longrightarrow A_{\tilde{\mathcal{L}}}$

Predicting $x \longrightarrow A_{\tilde{\mathcal{L}}} \longrightarrow p_p$

iii) Ensemble Learning

Verra' visto meglio in seguito ma non e' altro che un'approccio Bayesiano