Funzione Loss

Selezionare un predittore all'interno di una classe implica che esista una qualche metrica che quantifica quanto un predittore sia meglio di un'altro

Questa metrica e' chiamata rischio, ovvero l'errore di una predizione su un'elemento scelto a caso

Il rischio viene calcolato sulla base di una Loss function $L(h(x), t)$

Def

Per semplicità vediamolo funzionale, per il probabilistico valgono i stessi concetti

Dato un predittore $h: \mathcal{X} \to \mathcal{Y}$

Sia $x \in \mathcal{X}$, $y = h(x) \in \mathcal{Y}$ e $t \in \mathcal{Y}$

Definiamo

Varia in base al modello

$L: \mathcal{Y} \times \mathcal{Y} \to \mathbb{R}^{\geq 0}$ una funzione loss

Nello specifico L sta comparando $h(x)$ a t e ci quantifica quanto siano differenti: $L(x, h(x))$

Oss

Per il caso probabilistico invece della Loss function abbiamo una Scoring rule S

A questo poi bisogna associare il Pre-element risk $R(x)$ fissato $x \in \mathcal{X}$

Def

Il Pre-element risk $R(x)$ e' una funzione

$R: \mathcal{X} \to \mathbb{R}^{\geq 0}$

che fissato un $x \in \mathcal{X}$ calcola l'errore della nostra predizione rispetto al vero target e questa varia in base al tipo di relazione che lega le feature con il target:

- Funzionale:

  visto che $t = f(x)$ il nostro pre-element risk sara'

  $R(x) = L(y, f(x))$ ⇝ Stiamo pagando la differenza tra $y = h(x)$ e $f(x)$ ⇝ Noi vogliamo indovinare $f(x)$

- probabilistico:

  se dati e target sono legati in modo probabilistico possiamo dire che $t \sim p(\cdot|x)$, per cui abbiamo

  $$R(x) = \mathbb{E}_{t \sim p(\cdot|x)}[L(y, t)]$$

  ⇝ Valore atteso su tutti i possibili $t \sim p(\cdot|x)$

  ⇝ Vogliamo approssimare p

Se poi vediamo gli x in input come delle features generate mediante una distrib. p_x ed eseguendo l'approssimazione di $R(x)$ su tutti i possibili $x \sim p_x$ avremo il Rischio Atteso

Def

Il rischio atteso è definito come

$$\mathbb{E}_{x \sim p_x}[R(x)]$$

È anche in questo caso varia in base alla relazione che lega features e target:

- Funzionale:

$$\mathbb{E}_{x \sim p_x}[R(x)] = \mathbb{E}_{x \sim p_x}[L(y, f(x))]$$

- probabilistico:

In questo caso dovremo considerare direttamente l'estrazione delle coppie $(x,t) \sim p_{\tilde{z}}(x,t) = p_x(x)\, p_c(t|x)$

$$\mathbb{E}_{x \sim p_x}[R(x)] = \mathbb{E}_{x,t \sim p_{\tilde{z}}}[L(y,t)]$$

Assumendo di conoscere p_x rimangono però sconosciuti f e $p_{\tilde{z}}$ non possiamo applicare il rischio atteso

Per questo viene usato il rischio empirico

Rischio empirico

Def

Il rischio empirico è la media campionaria della funzione Loss su tutto il Training set

$$\widetilde{R}_{\tilde{z}}(h) = \frac{1}{|\tilde{z}|} \sum_{(x,t) \in \tilde{z}} L(h(x), t)$$

Vediamo ora le proprietà del rischio empirico e perché è una buona approx del rischio atteso

Proprietà

Sia $\tilde{z} = \{(x_1, t_1), \dots, (x_n, t_n)\}$ un training set estratto iid. con distrib. $p_{\tilde{z}}$ da $X \times Y$ con $|\tilde{z}| = n$ — indipendenti ed identicamente distribuite

Sia $L : Y \times Y \to \mathbb{R}$ una funzione Loss

Fissato un predittore $h : X \to Y$ ⇝ Attenzione! Ne stiamo fissando uno qualunque!!

Definiamo

$R_{P_{XY}}(h) = \mathbb{E}_{x,y \sim P_{XY}}[L(h(x), y)]$ il vero rischio atteso

$\widehat{R}_{\tilde{C}}(h) = \frac{1}{n}\sum_{i=1}^{n} L(h(x_i), y_i)$ il rischio empirico che stimiamo

Allora valgono (Non distorsione)

1) Unbiasedness:

$\forall L, P_{XY}\ \exists R_{P_{XY}}$ t.c. $\mathbb{E}_{\tilde{C} \sim P_{XY}^{n}}[\widehat{R}_{\tilde{C}}(h)] = R_{P_{XY}}$ → qualunque sia la size di $\tilde{C}$ ↝ Non dovrebbe essere per $n \to \infty$??

2) Consistenza

Per la legge debole dei grandi numeri possiamo dire che se $\exists R_{P_{XY}}$ Allora

$\widehat{R}_{\tilde{C}}(h) \xrightarrow{P} R_{P_{XY}}(h)$ per $|\tilde{C}| \to \infty$ → Al crescere di $|\tilde{C}|$ la prob. che $\widehat{R}_{\tilde{C}} \neq R_{P_{XY}}$ si avvicina a 0

3) Velocità di convergenza

Ponendo $\sigma_L^2 = \mathrm{Var}_{x,y \sim P_{XY}}(L(h(x), y))$ Abbiamo che $\mathrm{Var}\left(\widehat{R}_{\tilde{C}}(h)\right) = \sigma_L^2 / n$

Per cui

$\mathbb{P}\left(\left|\widehat{R}_{\tilde{C}}(h) - R_{P_{XY}}(h)\right| > \varepsilon\right) \leq \frac{\sigma_L^2(h)}{\varepsilon}$ → Chebyshev $\mathbb{P}(|X - \mathbb{E}[X]| > a) \leq \frac{\mathrm{Var}(X)}{a^2}$

Legge debole dei grandi numeri

Sia $\{X_i\}_{i=1,\dots,n}$ una seq. di V.A. iid con $\mathbb{E}[X_i] = \mu$, $\mathbb{E}[X_i^2] < \infty$ e $\mathrm{Var}(X_i) = \sigma^2$

Sia $\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$

Allora

$\bar{X}_n \xrightarrow{P} \mu$ ↝ $\lim_{n \to \infty} \mathbb{P}\left(|\bar{X}_n - \mu| > \varepsilon\right) = 0$ → La media campionaria non è molto differente rispetto alla media al crescere di n

Dim

$\lim_{n \to \infty} \mathbb{P}\left(|\bar{X}_n - \mu| > \varepsilon\right) \leq \lim_{n \to \infty} \frac{\mathrm{Var}(\bar{X}_n)}{\varepsilon^2} = \lim_{n \to \infty} \frac{\frac{1}{n^2}\sum_{i=1}^{n} \mathrm{Var}(X_i)}{\varepsilon^2} = \lim_{n \to \infty} \frac{n\sigma^2}{n^2\varepsilon^2} = 0$

Da queste proprietà capiamo quindi che più $|\tilde{C}|$ cresce meglio riusciamo ad approssimare $R_{P_{XY}}(h)$

Fino ad ora però abbiamo fissato h, in realtà però noi dobbiamo scegliere il predittore h all'interno di $\mathcal{H}$ → Insieme di tutti i predittori

Scelta del predittore

Sia $\mathcal{H}$ una famiglia di predittori

Ci poniamo ora il problema della scelta di un predittore $h \in \mathcal{H}$

Chiamiamo $h^* \in \mathcal{H}$ il miglior predittore che noi potremmo scegliere t.c.

$$h^* = \underset{h \in \mathcal{H}}{\operatorname{argmin}}\ R_{P_{\mathcal{D}}}(h)$$

↳ Non stiamo dicendo che $R_{P_{\mathcal{D}}}(h^*) = 0$ ma è semplicemente molto basso

Notiamo però che noi non conosciamo né potremmo conoscere h^* in quanto $R_{P_{\mathcal{D}}}$ non è calcolabile ↝ Non possiamo calcolare $P_{\mathcal{D}}$

Per questo viene definito $h_{\tilde{\mathcal{D}}}$ come il miglior predittore che noi possiamo trovare rispetto al $\tilde{\mathcal{D}}$ che conosciamo t.c.

$$h_{\tilde{\mathcal{D}}} = \underset{h \in \mathcal{H}}{\operatorname{argmin}}\ \widetilde{R}_{\tilde{\mathcal{D}}}(h)$$

↳ Empirical Risk Minimization

Che viene cercato secondo l'ERM

Sorgono ora 2 domande:

1) Possiamo provare tutte le $h \in \mathcal{H}$? ↝ Dipende da $|\mathcal{H}|$ e dalla potenza computazionale
2) Al crescere di $|\tilde{\mathcal{D}}|$, $h_{\tilde{\mathcal{D}}}$ è una buona approx di h^*?

Abbiamo visto che grazie alla legge debole dei grandi numeri

$$\lim_{|\tilde{\mathcal{D}}| \to \infty} \underset{h \in \mathcal{H}}{\operatorname{argmin}}\ \widetilde{R}_{\tilde{\mathcal{D}}}(h) = R_{P_{\mathcal{D}}}(h) \Rightarrow h_{\tilde{\mathcal{D}}} \to h^* \text{ per } |\tilde{\mathcal{D}}| \to \infty$$

↳ ☆

Però in realtà noi non possiamo fissare $h \in \mathcal{H}$ a prescindere dalla dimensione di $|\tilde{\mathcal{D}}|$ in quanto ERM sfrutta proprio $\tilde{\mathcal{D}}$ per scegliere $h_{\tilde{\mathcal{D}}}$

Infatti noi tramite ERM ci andiamo a calcolare per $|\tilde{\mathcal{D}}| \to \infty$

$$\lim_{|\tilde{\mathcal{D}}| \to \infty} \underset{h \in \mathcal{H}}{\operatorname{argmin}}\ \widetilde{R}_{\tilde{\mathcal{D}}}(h) \overset{?}{=} ☆$$

Cerchiamo ora di capire quanto $h_{\tilde{\mathcal{D}}}$ approssimi bene h^*

Calcoliamo

$$R_{P_{\mathcal{D}}}(h_{\tilde{\mathcal{D}}}) - R_{P_{\mathcal{D}}}(h^*) = R_{P_{\mathcal{D}}}(h_{\tilde{\mathcal{D}}}) - \widetilde{R}_{\tilde{\mathcal{D}}}(h_{\tilde{\mathcal{D}}}) + \widetilde{R}_{\tilde{\mathcal{D}}}(h_{\tilde{\mathcal{D}}}) - \widetilde{R}_{\tilde{\mathcal{D}}}(h^*) + \widetilde{R}_{\tilde{\mathcal{D}}}(h^*) - R_{P_{\mathcal{D}}}(h^*) \leq$$

↳ Aggiungiamo e sottraiamo $\widetilde{R}_{\tilde{\mathcal{D}}}(h_{\tilde{\mathcal{D}}})$ e $\widetilde{R}_{\tilde{\mathcal{D}}}(h^*)$

↳ sempre ≤ 0 visto che h^* è sempre migliore rispetto ad $h_{\tilde{\mathcal{D}}}$

$$\leq \left| R_{P_{\mathcal{D}}}(h_{\tilde{\mathcal{D}}}) - \widetilde{R}_{\tilde{\mathcal{D}}}(h_{\tilde{\mathcal{D}}}) \right| + \left| \widetilde{R}_{\tilde{\mathcal{D}}}(h^*) - R_{P_{\mathcal{D}}}(h^*) \right| \leq$$

$$\leq 2 \sup_{h \in H} \left| \widehat{R}_{\tilde{c}}(h) - R_{\tilde{P}}(h) \right|$$

Prendiamo l'h che aumenta questa distanza

Per cui abbiamo che

$$\mathbb{P}\left(R_{P_{\tilde{c}}}(h_{\hat{c}}) - R_{P_{\tilde{c}}}(h^*)\right) \leq \mathbb{P}\left(2 \sup_{h \in H} \left| \widehat{R}_{\tilde{c}}(h) - R_{P_{\tilde{c}}}(h) \right|\right)$$

Questo ci dice che per $|\tilde{c}| \to \infty$ il rischio empirico converge al rischio atteso uniformemente su tutto H piuttosto che su singoli $h \in H$

Per cui una condizione sufficiente affinché $h_{\hat{c}}$ sia una buona approx di h^* è che $\forall h \; \widehat{R}_{\tilde{c}}(h)$ sia simile a $R_{P_{\tilde{c}}}(h)$