Scelta di un predittore

Abbiamo visto le proprietà di $h_{\tilde{z}}$ scelto mediante l'ERM e come questo sia una buona approx di h^*

Resta ora la questione della scelta di $\mathcal{H}$

Def

Innanzitutto andiamo a definire l'Accuracy come

$$\text{Accuracy} = \frac{\#\text{ di predizioni esatte}}{\#\text{ di predizioni totali}}$$

Oss

Può essere calcolata solo su dati che conosciamo

Siano $\mathcal{H}_1, \dots, \mathcal{H}_K$ delle famiglie di predittori

Sia $D = \{(x_1, t_1), \dots, (x_n, t_n)\}$ il nostro dataset → fino ad ora lo chiamavamo $\tilde{z}$ training set

Vediamo ora i vari approcci per la scelta di $\mathcal{H}$ e del predittore da usare $h^*_{\mathcal{H}}$ in base a D

Approccio Naive

L'approccio più banale è quello di:

i) Dividere il dataset in 2 parti: $\tilde{z}$ training set $\tilde{z}$ e $\tilde{z}$ test set

ii) $\forall i = 1, \dots, K$ calcolare $h_{\tilde{z}, \mathcal{H}_i} \in \mathcal{H}_i$ mediante ERM solo su $\tilde{z}$

iii) $\forall i = 1, \dots, K$ calcolare l'Accuracy di $h_{\tilde{z}, \mathcal{H}_i}$ sui dati appartenenti al $\tilde{z}$ test set

iv) Selezionare fra tutti i predittori $h_{\tilde{z}, \mathcal{H}_i}$ quello con l'Accuracy più alta h^*

Oss

La divisione del Dataset permette di evitare il problema dell'overfitting

Calcolando in fatti l'Accuracy su $\tilde{z}$ questa sarà sempre altissima visto che per def $h_{\tilde{z}, \mathcal{H}_i}$ viene scelto in modo da minimizzare $\hat{R}_{\tilde{z}}$ e aumentare indirettamente l'Accuracy

Per questo i vari $h_{\tilde{z}, \mathcal{H}_i}$ vengono scelti a partire dal $\tilde{z}$ e poi l'Accuracy viene calcolata sul $\tilde{z}$ test set contenente dati mai visti prima

Questo approccio però ha un problema:

Andando a selezionare h^* come il predittore che massimizza l'Accuracy sul $\widetilde{Test\ set}$ stiamo a conti fatti scegliendo il predittore che si comporta meglio sull'intero Data set senza sapere come questo si possa comportare su dati mai visti prima

Approccio Model selection

Per risolvere questa criticità si è modificato l'Approccio Naive in questo modo:

i) Si divide il Dataset D in 3 parti:

$\widetilde{Training\ set}$, Validation set e $\widetilde{Test\ set}$

ii) $\forall i=1,\dots,K$ calcolare $h_{\widetilde{\mathcal{L}},H_i} \in H_i$ mediante ERM solo su $\widetilde{\mathcal{L}}$

iii) $\forall i=1,\dots,K$ calcolare l'Accuracy di $h_{\widetilde{\mathcal{L}},H_i}$ sui dati appartenenti al Validation set

iv) Selezionare fra tutti i predittori $h_{\widetilde{\mathcal{L}},H_i}$ quello con l'Accuracy più alta h^*

v) Calcolarne le prestazioni calcolando l'Accuracy di h^* sul $\widetilde{Test\ set}$

In questo modo si sta usando il $\widetilde{Test\ set}$ solo per la valutazione del predittore evitando il problema dell'overfitting

Oss

In realtà se h^* si comporta male sul $\widetilde{Test\ set}$ bisognerebbe sceglierne un secondo incappando così nello stesso problema riscontrato nell'approccio Naiv

Però incappare nell'overSibling dopo la valutazione sul $\widetilde{Test\ set}$ è molto improbabile???

Approccio K-fold Cross Validation

Per aumentare i predittori da poter scegliere è stato modificato il Model selection nel seguente modo:

i) Dividere D in 2 sezioni:

- Una prima sezione da dividere a sua volta in K partizioni $d_1,\dots,d_K$
- Il Test set

ii) $\forall i=1,\dots,K$ Viene estratto h_i^* eseguendo la Model Based selection dove d_i è il Validation set e $Vd_{j\neq i}$ viene trattato come $\widetilde{Training\ set}$

iii) Si vede il comportamento in media dei vari h_i^* sul $\widetilde{Test\ set}$

Oss

In questo modo si riesce ad avere un numero maggiore di predittori

Stimatore Bayesiano

Def

Definiamo come stimatore Bayesiano il miglior predittore in assoluto, senza alcun tipo di restrizione su $\mathcal{H}$

$$h^B = \underset{h}{\operatorname{argmin}}\, R_{P_{XY}}(h)$$

Possiamo definire poi il Rischio Bayesiano come

$$R^B_{P_{XY}} = R_{P_{XY}}(h^B)$$

Lo stimatore Bayesiano così definito è un benchmark perfetto per indicare i limiti del Machine Learning per una determinata task

Definire così lo stimatore Bayesiano ci porta ad avere diverse conseguenze

i) h^B non dipende solo da P_{XY} ma anche dalla Loss
→ Loss diverse estraggono statistiche diverse a partire dalla stessa $P_Z(t|x)$

ii) Calcolare h^B richiede necessariamente $P_Z(\cdot|x)$, quindi h^B è incalcolabile
→ Per questo h^B è un benchmark e non un metodo di Training

Dato $R^B_{P_{XY}}$ lo possiamo usare per capire quanto sia buono il nostro stimatore

Siano $\mathcal{H}$ la famiglia scelta, $h^*_{\mathcal{H}} = \underset{h\in\mathcal{H}}{\operatorname{argmin}}\, R_{P_{XY}}(h)$ e $h_{\tilde{\mathcal{Z}}} = \underset{h\in\mathcal{H}}{\operatorname{argmin}}\, \tilde{R}_{\tilde{\mathcal{Z}}}(h)$

Abbiamo che

$$R_{P_{XY}}(h_{\tilde{\mathcal{Z}}}) - R^B_{P_{XY}} = \underbrace{R_{P_{XY}}(h_{\tilde{\mathcal{Z}}}) - R_{P_{XY}}(h^*_{\mathcal{H}})}_{A} + \underbrace{R_{P_{XY}}(h^*_{\mathcal{H}}) - R^B_{P_{XY}}}_{B}$$

Dove

i) sia A che B sono non-negativi → A causa delle definizioni di $h_{\tilde{\mathcal{Z}}}, h^*_{\mathcal{H}}, h^B$

ii) A è chiamato estimation error:

Comparando $h^*_{\mathcal{H}}$ e $h_{\tilde{\mathcal{Z}}}$ all'interno dello stesso $\mathcal{H}$ è una metrica di quanto $h_{\tilde{\mathcal{Z}}}$ si basi su $\tilde{\mathcal{Z}}$ piuttosto che sul pattern sottostante

Diminuisce all'aumentare di $|\tilde{\mathcal{Z}}|$ ma aumenta tanto più $|\mathcal{H}|$ si ingrandisce

Viene solitamente associato all'overfitting

iii) B è chiamato approximation error:

Comparando $h^*_{\mathcal{H}}$ e h^B è una metrica di quanto la famiglia $\mathcal{H}$ sia una buona scelta all'interno di tutte le possibili $\mathcal{H}$

Diminuisce al crescere di $|\mathcal{H}|$

Viene associato all'underfitting